



山东大学
SHANDONG UNIVERSITY

毕业论文（设计）

论文（设计）题目： 使用深度学习在 SNO+ 实验进行位置重建

姓 名	秦祥语
学 号	202122161288
学 院	泰山学堂
专 业	物理学
年 级	2021 级
指导教师	张洋教授

2025 年 4 月 30 日

摘要

萨德伯里中微子观测站 + 是开创先河的萨德伯里中微子观测站的后续项目。它位于加拿大萨德伯里地下约 2 千米处。它的主要物理目标是探测一个极其罕见的事件——无中微子双贝塔衰变。如果这一现象被观测到，它将为中微子物理和基本粒子理论提供深远的启示。为了实现这一目标，该实验使用一个装有 780 吨液体闪烁体的直径约 12 米的丙烯酸容器探测器，该探测器随后将被装载 1.3 吨的同位素碲-130。精确的包括事件位置，方向，时间，能量的事件重建对于区分无中微子双贝塔衰变和背景事件的信号至关重要。中微子实验中的传统事件重建通常使用数值方法，并且基于最大似然估计。尽管这些方法被广泛地使用，但是当我们处理复杂的事件，大量的噪声或者大量的数据时，这些方法将会面临很大的局限，导致重建精度受限和计算效率低下。不过，深度学习的方法凭借其强大的捕捉复杂，非线性关系的能力在粒子物理领域尤其是事件重建中显现出了其对事件重建性能提升的潜力。

尽管深度学习方法取得了令人期待的成就，但是评估模型的预测的可靠性和鲁棒性仍然是一个重要的挑战。特别是需要全面的不确定性量化来确保基于深度学习的方法的重建的可信度。对于不确定性的量化，包括数据驱动的和模型相关的不确定性，不仅对于控制预测的置信度以防止过拟合和欠拟合很有必要，而且对于后续的物理分析也很重要。

在本论文中，我们提出了一种专为 SNO+ 实验设计全新的深度学习驱动的事件重建方法。这一模型采用基于生成预训练 Transformer 结构的神经网络架构。为了训练和验证我们的模型，我们使用了依托实验反应堆分析工具的蒙特卡洛模拟数据。此外，我们还引入了一种利用液体闪烁体中自然放射性同位素铋-214 和钋-214 的事件验证新方法。这种方法不仅稳定可靠，还能实现基于数据的高精度重建验证。

经过系统评估，我们的结果显示，即使训练时间较短，所开发的深度学习模型也能在重建精度、计算效率，以及对探测器噪声和不确定性表现出令人满意的鲁棒性。更值得注意的是，通过蒙特卡洛 Dropout 技术，我们能够同时对数据驱动与模型驱动的不确定性进行估计，从而深入理解事件重建的模型置信度。

总体而言，本研究提出并验证了一种融合不确定性估算的新型深度学习重建方法，同时为中微子物理实验中的数据分析提供了新的思路。这一方法不仅适用于 SNO+ 等

实验，还可以根据需要，应用于其他中微子或稀有事件探测实验。

关键词：双贝塔衰变；中微子物理；重建；深度学习；不确定性估计；液体闪烁体探测器

ABSTRACT

The Sudbury Neutrino Observatory+ experiment is the successor to the pioneering Sudbury Neutrino Observatory. It is located approximately 2km underground in Sudbury, Canada. Its primary physics goal is to detect a very rare event, neutrinoless double-beta decay. This phenomenon would provide profound implications for neutrino physics and fundamental particle theory if observed. To achieve this goal, the experiment employs a detector filled with 780 tonnes of liquid scintillator, which will subsequently be loaded with approximately 1.3 tonnes of the isotope ^{130}Te in its 12-meter diameter acrylic vessel. Precise event reconstruction, including accurate determination of event location, direction, timing, and energy, is crucial for distinguishing the subtle signals of neutrinoless double-beta decay from background events.

Traditionally, event reconstruction in neutrino experiments usually implement numerical methods, and often based on maximum likelihood estimation. Although it's widely employed, these methods has a high probability to face limitations when dealing with complex events, substantial noise, or large datasets, leading to constrained reconstruction accuracy and computational inefficiencies. However, deep learning techniques have emerged prominently especially for the event reconstruction task in the field of particle physics, which has demonstrated significant potential for enhancing reconstruction performance due to their exceptional capability of capturing intricate, nonlinear relationships from large-scale datasets.

Despite the promising achievements brought by deep learning approaches, assessing the reliability and robustness of model predictions remains a critical challenge. Specifically, comprehensive uncertainty quantification is required to ensure the scientific credibility of deep learning-based position reconstruction algorithms. Quantifying uncertainties, including aleatoric (data-driven) and epistemic (model-related) uncertainties, is essential not only for controlling the confidence of predictions to avoid overfitting or underfitting, but also for the subsequent physical analysis.

In this thesis, we present a novel deep learning-based event reconstruction algorithm

which is specialized to fit the unique characteristics of the experiment. The proposed model implements Generative Pre-trained Transformer-based architectures. To train and validate our deep learning model, we have used Monte Carlo simulation data based on the reactor analysis tool in the experiment. Moreover, we introduced an innovative validation method based on naturally occurring radioactive ^{214}Bi - ^{214}Po coincidence events within the scintillator. This method offers a robust, data-driven validation approach to evaluate the reconstruction accuracy of our model.

Through systematic assessments, our results demonstrate that the developed deep learning model with little training of a relatively small dataset can reach almost the same performance traditional maximum likelihood estimation-based methods in terms of reconstruction precision, computational efficiency, and robustness to detector noise and uncertainties. Importantly, the implementation of Monte Carlo Dropout techniques has shown the potential to have simultaneous quantification of both aleatoric and epistemic uncertainties, providing comprehensive insight into the confidence levels of reconstruction results.

Overall, this research proposes and validates an innovative deep learning-based reconstruction framework with integrated uncertainty estimation, and contributes to advancing data analysis methodologies in neutrino physics experiments. The methodologies developed here have broader implications and can be adapted to other neutrino or rare-event detection experiments later after modification.

Key Words: Double-beta decay, Neutrino physics, Reconstruction, Deep Learning, Uncertainty estimation, Liquid scintillator detector

目 录

第一章 前言	1
1.1 研究背景	1
1.2 研究目的	2
1.3 论文内容安排	2
第二章 中微子物理	3
2.1 中微子的发现历程	3
2.2 中微子振荡	3
2.3 中微子质量	4
2.4 双贝塔衰变	6
2.4.1 $2\nu\beta\beta$	6
2.4.2 $0\nu\beta\beta$	7
2.5 $0\nu\beta\beta$ 实验	7
第三章 深度学习以及其不确定性量化简介	9
3.1 神经网络基础架构简介	9
3.2 Transformer	11
3.2.1 注意力机制	11
3.3 深度学习中的不确定性分析	13
3.3.1 BNN	13
3.3.2 MC Dropout	15
3.3.3 深度集成	15
3.4 本章小结	16
第四章 SNO+ 实验	18
4.1 物理目标	18
4.2 SNO+ 实验装置	19
4.3 SNO+ 实验中的背景事件	20

4.4 小结	21
第五章 SNO+ 实验的位置重建以及不确定性量化	22
5.1 SNO+ 探测器中传统的位置重建方法	22
5.2 深度学习在 SNO+ 探测器中的位置重建方法	23
5.3 数据集	24
5.4 位置重建模型架构	24
5.4.1 输入与嵌入	25
5.4.2 Transformer 编码器	25
5.4.3 输出层与损失函数	25
5.4.4 模型训练	25
5.5 深度学习位置重建结果	27
5.6 位置重建不确定性的量化	27
5.6.1 粒子物理实验中不确定性的估计	29
5.6.2 在深度学习中量化不确定性的方法	30
5.6.3 不确定性量化结果	30
第六章 总结与展望	33
6.1 总结	33
6.2 展望	33
参考文献	35
致 谢	37
附录 A 池化	38
A.1 模型中的池化应用：带掩码的平均池化	38
A.1.1 具体实现	39
附录 B 层归一化	40
B.0.1 层归一化原理	40
B.0.2 层归一化的优势	41
B.0.3 在模型中的应用	41

第一章 前言

1.1 研究背景

中微子是粒子物理学研究的热点之一。它也是标准模型中最轻的基本粒子之一，具有极小的质量，且与物质的相互作用非常微弱，因此它们在宇宙中的传播几乎不受阻碍。中微子振荡现象的发现，表明了中微子具有非零质量，并且不同味道中微子之间可以相互转化，这一发现对粒子物理学和宇宙学都产生了深远的影响，也是目前确凿的超出标准模型的物理现象。日本的超级神冈 (Super-Kamiokande) 和加拿大 SNO (Sudbury Neutrino Observatory, 萨德伯里中微子观测站) 实验等一系列实验，验证了中微子振荡现象^{[1][2]}，并测量了中微子的质量差和混合角。这些实验结果为我们理解中微子的性质提供了重要的实验依据。而中微子仍旧是存在未解之谜，许多问题仍然悬而未决。例如，中微子的质量是多少？中微子是否是其自身的反粒子，即中微子是否是马约拉纳粒子？这些问题的解决将有助于我们更深入地理解基本粒子的性质和宇宙的演化。

SNO 实验在完成了太阳中微子振荡的测量后，为了提高探测器的灵敏度和分辨率进行了一系列升级改进。SNO+ 实验^{[3][4]} 是 SNO 实验的后续项目，旨在利用液体闪烁体探测器对中微子进行更精确的测量，以及测量二重中微子双贝塔衰变 ($2\nu\beta\beta$) 的半衰期和寻找一个极其稀有的事件——无中微子双贝塔衰变 ($0\nu\beta\beta$)^[4]。SNO+ 实验采用了液体闪烁体作为探测介质，具有较高的光产额，可以有效地提高中微子的探测效率。液体闪烁体探测器相比传统的水切伦科夫探测器，具有更高的能量分辨率和更好的时间分辨率，因此可以用于探测低能中微子事件。但是，由于液体闪烁体退激发产生的闪烁光产额远大于切伦科夫光，导致在进行事件的重建时相比于传统的水切伦科夫探测器更加困难。因此，合适的事件重建算法在大型液体闪烁体探测器中显得尤为重要。

传统的事件重建算法主要基于最大似然估计的方法，并通过对探测器响应的模拟和拟合来实现事件的重建。这些算法通常需要对探测器的物理过程进行详细的建模，面对噪声和背景事件很容易被影响。近年来，深度学习技术的发展，由数据驱动的方法在事件重建中逐渐显现出其优势。深度学习方法通过对大量实验数据的学习，自动提取特征并进行事件重建，具有更好的适应性和鲁棒性。

但是，深度学习方法在事件重建中的应用仍然有需要关注的地方。一般来讲，深度学

习训练出的模型在进行预测的时候，给出的结果是一个单值，而不是一个分布，这使得模型在进行预测的时候缺乏不确定性评估。同时，模型本身进行预测时也会带来一定的不确定性。模型的不确定性以及数据本身的统计不确定性都会影响到模型的预测结果。因此，如何对深度学习模型进行不确定性评估，并将其应用于事件重建中，是一个重要的研究方向。

1.2 研究目的

本论文研究目的为研究基于深度学习的事件重建方法，并对其进行不确定性评估。我们将采用深度学习模型对液体闪烁体探测器中的中微子事件进行重建，并对模型的预测结果进行不确定性评估。通过使用不确定性评估方法，分析其在事件重建中的应用效果，为后续的实验数据分析提供参考。

1.3 论文内容安排

本文的第一章首先介绍了中微子物理学的背景和研究现状，第二章重点介绍了中微子的发现历程和双贝塔衰变现象；第三章介绍了深度学习以及其带来的不确定性分析；第四章介绍了 SNO+ 实验，重点介绍在该实验中传统的重建方法；第五章介绍了基于深度学习的事件重建方法，并对其进行不确定性评估；最后一章总结了本文的研究工作，并说明了未来可以在 SNO+ 实验进行进一步研究并实施的方向，方法。

第二章 中微子物理

中微子一直是粒子物理学中一个非常有趣且受到广泛关注的研究方向。它们属于标准模型中的轻子，质量很小，并且与其他物质的相互作用非常微弱，让我们很难去直接观察到它们的存在。不过，研究中微子对理解宇宙的起源和演变、以及基本粒子之间的关系都非常重要。它们在宇宙中扮演着重要角色，不仅参与核反应和高能宇宙射线的产生，还可能在宇宙的膨胀和冷却过程中起到一定的作用。

本章节主要介绍中微子物理，2.1节回顾了中微子的发现历程，2.2节简要介绍了中微子振荡现象，2.3节介绍了中微子质量以及 2.4节介绍了双贝塔衰变的相关问题。

2.1 中微子的发现历程

1914 年，Chadwick J. 在研究 β 衰变过程中发现了一个令人困惑的问题： β 衰变中电子的能量呈现出连续分布的谱线，而非单一常数值。这一现象与当时理论预期的单一能量释放过程不符。为了解释这一现象，1930 年，Pauli W. 提出了一个假设：在 β 衰变过程中，除了电子外，还存在一个未被观测到的粒子参与其中，这个粒子后来被称为“中微子”。1934 年，Fermi E. 提出了中微子与电子的相互作用理论，并正式将其命名为“中微子”。1942 年王淦昌首先提出使用电子俘获的方法来探测中微子，而直到 1956 年，Reines F. 和 Cowans C. 才首次在实验中成功探测到了中微子，证实了它们的存在。^[5] 到 1962 年，Lederman L. 等人发现中微子不止一种，除了之前发现的电子中微子外，他们还发现了 μ 子中微子。当第三种轻子 τ 子于 1975 年被发现后，科学家们又在 2000 年证实了第三种中微子—— τ 中微子的存在。这三种中微子具有不同的味道，分别对应三种轻子：电子、 μ 子和 τ 子。

2.2 中微子振荡

由超级神冈对于大气中微子中穿过地球的 μ 子中微子缺失测量的结果和由 SNO 实验通过对太阳中微子的带电流和中性流的测量对“太阳中微子消失之谜”的解答可以看出，中微子在传播过程中会发生振荡现象，即中微子的三种味道会在其传播过程相互转化。这意味着中微子是具有内禀时钟，从而得出了与标准模型的预测完全不同的结果

——中微子具有静止质量。中微子振荡的现象可以用一个简单的模型来描述。现在有三种我们可以探测到的中微子，分别是电子中微子 ν_e 、 μ 子中微子 ν_μ 和 τ 子中微子 ν_τ 。那么根据薛定谔方程，考虑平面波，在真空中，从一种味道中微子 $|\nu_\alpha\rangle$ 到另一种味道 $|\nu_\beta\rangle$ 的转化的概率是：¹

$$P_{\nu_\alpha \rightarrow \nu_\beta} = \delta_{\alpha\beta} - 4 \sum_{i>j=1} \mathbf{Re}(K_{\alpha\beta,ij}) \sin^2 \left(\frac{\Delta m_{ij}^2 L}{4E} \right) - 4 \sum_{i>j=1} \mathbf{Im}(K_{\alpha\beta,ij}) \sin \left(\frac{\Delta m_{ij}^2 L}{2E} \right) \quad (2.1)$$

其中

$$K_{\alpha\beta,ij} = U_{\alpha i} U_{\beta i}^* U_{\alpha j} U_{\beta j}^* \quad (2.2)$$

Δm_{ij}^2 为质量本征态 $|\nu_i\rangle$ 与质量本征态 $|\nu_j\rangle$ 的平方差值， $L = x = ct$ 为中微子源到探测器的距离。 U 为 PMNS 矩阵：

$$|\nu_\alpha\rangle = U_{PMNS} |\nu_i\rangle \quad \alpha = e, \mu, \tau; i = 1, 2, 3 \quad (2.3)$$

$$U = \begin{pmatrix} 1 & 0 & 0 \\ 0 & c_{23} & s_{23} \\ 0 & -s_{23} & c_{23} \end{pmatrix} \begin{pmatrix} c_{13} & 0 & s_{13}e^{-i\delta} \\ 0 & 1 & 0 \\ -s_{13}e^{i\delta} & 0 & c_{13} \end{pmatrix} \begin{pmatrix} c_{12} & s_{12} & 0 \\ -s_{12} & c_{12} & 0 \\ 0 & 0 & 1 \end{pmatrix} \quad (2.4)$$

其中 $s_{ij} = \sin \theta_{ij}$ ， $c_{ij} = \cos \theta_{ij}$ ($i, j = 1, 2, 3$)， θ_{ij} 为混合角， δ 为 CP 相位。这是对于 Dirac 中微子的 PMNS (Pontecorvo-Maki-Nakagawa-Sakata) 矩阵，而对于 Majorana 中微子，会引入额外的两个相位参数：

$$U = U_{PMNS} \cdot \text{diag}(1, e^{i\alpha_1}, e^{i\alpha_2}) \quad (2.5)$$

但是不影响整体的中微子振荡，因为取模之后这些因子都被消去了。

2.3 中微子质量

中微子振荡的发现打开了中微子研究的新领域，其中最重要的问题是，既然中微子具有质量，那么它们的质量是多少？以及它们的质量是如何产生的呢？一般认为，中微子

¹这里考虑了相对论效应，且由于中微子能量 E 远大于中微子静止质量 m ，故可以在自然单位制下近似认为 $E = \bar{p}$ ， \bar{p} 为中微子的平均动量。

质量有两种来源：一是通过希格斯机制，类似于其他费米子。另外一种猜测是中微子可能是一直没有被发现的 Majorana 费米子，即中微子的反粒子是它本身。对于 Majorana 中微子，需要超出标准模型的理论进行解释。一个最吸引人的模型是所谓的”翘翘板”机制，其引入了具有超大 Majorana 质量项的右手中微子，从而可以获得一个超大的质量本征值和一个很小的质量本征值。

考虑左手中微子和超大质量的右手中微子以及对应的反中微子通过 Dirac 质量项和 Majorana 质量项的耦合，其拉格朗日量为^{[6]1}：

$$2\mathcal{L} = m_D(\bar{\nu}_L N_R + \bar{N}_L^c \nu_R^c) + m_L \bar{\nu}_L \nu_R^c + m_R \bar{N}_L^c N_R + h.c. \quad (2.6)$$

$$= (\bar{\nu}_L, \bar{N}_L^c) \begin{pmatrix} m_L & m_D \\ m_D & m_R \end{pmatrix} \begin{pmatrix} \nu_R^c \\ N_R \end{pmatrix} + h.c. \quad (2.7)$$

其中 ν_L 为左手中微子， ν_R^c 为其对应的反中微子， m_L 为其质量 N_R 为引入的超大质量中微子， N_L^c 为其对应的反中微子。 m_R 为其质量。 m_D 为 Dirac 质量项， m_R 为 Majorana 质量项。在标准模型中，Majorana 质量项不能出现，因为它不是规范不变的。对于刚才提到的最简单的”翘翘板”机制，我们只需要令 $m_L = 0$ ， $m_R \gg m_D$ ，则我们得到了两个质量本征态：

$$m_\nu = m_1 = \frac{m_D^2}{m_R} \quad m_N = m_2 = m_R \left(1 + \frac{m_D^2}{m_R^2}\right) \approx m_R \quad (2.8)$$

图2.1是一个费米场，轻子以及中微子通过 Dirac 质量和 Majorana 质量耦合的示意图。(a) 为费米场的质量产生机制，(b) 为电子的质量产生机制，(c) 为”翘翘板”机制下中微子的质量产生机制，即上面的分析。




图 2.1 费米场，电子，中微子通过 Dirac 质量和 Majorana 质量耦合的示意图^[6]

¹式中 $h.c.$ 代表厄米共轭

2.4 双贝塔衰变

$\beta\beta$ (Double Beta Decay, 双贝塔衰变) 是一种非常罕见的放射性衰变过程。在这种衰变中, 原子核内的两个中子 (或质子) 同时转变为两个质子 (或中子), 并释放出两个电子 (或正电子) 以及可能的中微子。

这个过程之所以受到关注, 是因为它只发生在那些单贝塔衰变 (一个中子转变为一个质子, 释放一个电子和一个反中微子) 在能量上被禁止或者因为角动量选择定则而被高度压制的原子核中。换句话说, 如果一个原子核满足

$$m(Z, A) > m(Z + 2, A) \quad m(Z, A) < m(Z + 1, A) \quad (2.9)$$

那么它就可能经历 $\beta\beta$ 。 $\beta\beta$ 主要有两种模式: $2\nu\beta\beta$ (Two-neutrino double beta decay, 双中微子双贝塔衰变) 和 $0\nu\beta\beta$ (Neutrinoless double beta decay, 无中微子双贝塔衰变)。

2.4.1 $2\nu\beta\beta$

$2\nu\beta\beta$ 是标准模型框架中允许的过程。原子核内的两个中子转变为两个质子, 同时释放出两个电子和两个电子反中微子 ($\bar{\nu}_e$)。反应式可以写为:

$$(A, Z) \rightarrow (A, Z + 2) + 2e^- + 2\bar{\nu}_e \quad (2.10)$$

这个过程遵守轻子数守恒定律 (初始轻子数为 0, 末态轻子数为 $2 \times (+1) + 2 \times (-1) = 0$)。这一理论首先被 Goeppert M. 提出^[7], $2\nu\beta\beta$ 衰变已经被实验明确观测到, 其半衰期极长, 通常在 10^{18} 到 10^{21} 年的量级或更长^[8]。

$\beta\beta$ 的半衰期 ($T_{1/2}$) 可以通过以下公式描述:

对于 $2\nu\beta\beta$:

$$[T_{1/2}^{2\nu}]^{-1} = G^{2\nu}(Q, Z)|M^{2\nu}|^2 \quad (2.11)$$

其中 $T_{1/2}^{2\nu}$ 是 $2\nu\beta\beta$ 衰变的半衰期。 $G^{2\nu}(Q, Z)$ 是可精确计算的相空间因子 (Phase Space Factor), 它依赖于衰变能量 Q 和原子核的电荷数 Z 。 $M^{2\nu}$ 是核矩阵元 (Nuclear Matrix Element, NME), 它的计算高度依赖于核物理模型, 是理论计算中的主要不确定性来源。

2.4.2 $0\nu\beta\beta$

$0\nu\beta\beta$ 是一个尚未被实验发现的极其稀有的过程。这个反应包括了原子核内的两个中子转变为两个质子，只释放出两个电子，而没有中微子被释放出来。反应式可以写为：

$$(A, Z) \rightarrow (A, Z + 2) + 2e^- \quad (2.12)$$

这个过程违反了轻子数守恒定律 ($\Delta L = +2$)。它的发生需要满足两个关键条件：

1. 中微子是 Majorana 粒子，即中微子和它的反粒子是同一种粒子 ($\nu = \bar{\nu}$)。
2. 中微子具有非零的质量。

在这个模型中，一个中子衰变放出一个电子和一个“反中微子”，这个“反中微子”因为是 Majorana 粒子，可以被第二个中子当作“中微子”吸收，并促使第二个中子衰变放出一个电子。Furry M. 在 1939 年首次提出可以通过寻找 $0\nu\beta\beta$ 来对中微子的本质做出判断。^[9]

对于 $0\nu\beta\beta$ ：

$$[T_{1/2}^{0\nu}]^{-1} = G^{0\nu}(Q, Z) |M^{0\nu}|^2 |\langle m_{\beta\beta} \rangle|^2 \quad (2.13)$$

其中： $T_{1/2}^{0\nu}$ 是 $0\nu\beta\beta$ 衰变的半衰期。 $G^{0\nu}(Q, Z)$ 是相应的相空间因子。 $M^{0\nu}$ 是 $0\nu\beta\beta$ 过程的核矩阵元。 $\langle m_{\beta\beta} \rangle$ 是有效 Majorana 中微子质量，它是粒子物理学非常关注的参数。它与中微子质量本征值 (m_1, m_2, m_3) 和混合矩阵 (PMNS 矩阵) 的元素 (U_{ei}) 相关：


$$\langle m_{\beta\beta} \rangle = \left| \sum_{i=1}^3 U_{ei}^2 m_i \right| \quad (2.14)$$

这里求和遍历所有三个中微子质量本征态 $i = 1, 2, 3$ 。 U_{ei} 是 PMNS 矩阵中连接电子味态和质量本征态 i 的元素。

2.5 $0\nu\beta\beta$ 实验

由于 $0\nu\beta\beta$ 衰变的半衰期预计比 $2\nu\beta\beta$ 更长 (如果存在的话，至少 $> 10^{26}$ 年)，实验探测极其困难。实验需要在极低的放射性本底下运行，使用大量的同位素源，并具备极高的能量分辨率来区分 $2\nu\beta\beta$ 衰变 (电子能量是连续谱) 和 $0\nu\beta\beta$ 衰变 (两个电子的总能量是一个固定值，等于衰变能 Q)，如图2.2所示。世界各地有许多实验正在进行或计划中，例如 GERDA/LEGEND，CUORE，EXO-200/nEXO，KamLAND-Zen，MAJORANA Demonstrator，NEXT，SNO+ 等。

衰变	Q-value (keV)	自然界丰度 (%)	$G^{0\nu}$	$G^{2\nu}$
$^{48}_{20}\text{Ca} \rightarrow ^{48}_{22}\text{Ti}$	4262.96 ± 0.84	0.187	24.65	15536
$^{76}_{32}\text{Ge} \rightarrow ^{76}_{34}\text{Se}$	2039.006 ± 0.050	7.8	2.372	46.47
$^{82}_{34}\text{Se} \rightarrow ^{82}_{36}\text{Kr}$	2997.9 ± 0.3	9.2	10.14	1573
$^{96}_{40}\text{Zr} \rightarrow ^{96}_{42}\text{Mo}$	3356.097 ± 0.086	2.8	20.48	6744
$^{100}_{42}\text{Mo} \rightarrow ^{100}_{44}\text{Ru}$	3034.40 ± 0.17	9.6	15.84	3231
$^{110}_{46}\text{Pd} \rightarrow ^{110}_{48}\text{Cd}$	2017.85 ± 0.64	11.8	4.915	132.5
$^{116}_{48}\text{Cd} \rightarrow ^{116}_{50}\text{Sn}$	2813.50 ± 0.13	7.5	16.62	2688
$^{124}_{50}\text{Sn} \rightarrow ^{124}_{52}\text{Te}$	2292.64 ± 0.39	5.64	9.047	551.4
$^{130}_{52}\text{Te} \rightarrow ^{130}_{54}\text{Xe}$	2527.518 ± 0.013	34.5	14.25	1442
$^{136}_{54}\text{Xe} \rightarrow ^{136}_{56}\text{Ba}$	2457.83 ± 0.37	8.9	14.54	1332
$^{150}_{60}\text{Nd} \rightarrow ^{150}_{62}\text{Sm}$	3371.38 ± 0.20	5.6	61.94	35397

 表 2.1: 不同核素 $\beta\beta$ 的 Q 值和相空间因子^[8]

 图 2.2: $0\nu\beta\beta$ 和 $2\nu\beta\beta$ 衰变的能谱对比 (非真实比例)

第三章 深度学习以及其不确定性量化简介

深度学习通过构建多层非线性变换网络实现对数据特征的层次化抽象，已成为现代人工智能的核心范式。本章在3.1节中介绍了神经网络的基础架构，阐述深度学习的基础理论框架，重点解析神经网络的结构特性与训练机制，在3.2节深入探讨了 Transformer 模型的自注意力机制，并在3.3节全面论述了不确定性量化的前沿方法与技术挑战。

3.1 神经网络基础架构简介

神经网络是一种模拟人脑神经元结构和功能的计算模型。它由大量的神经元通过连接权重相互连接而成。神经网络跟生物上的神经系统类似，其基本单元都是神经元，每个神经元接收来自其他神经元的输入信号，并在神经元之间通过激活函数引入非线性关系将其转换为输出信号。神经网络的学习过程就是通过调整连接权重来最小化预测值与真实值之间的误差。一般来说，一个简单的神经网络的结构通常分为输入层、隐藏层和输出层。输入层接收从外界输入的数据，接着经过处理之后传递到隐藏层，同时通过激活函数对输入数据进行非线性变换，最后输出层会将隐藏层的输出转换为最终的预测结果（通常为点估计）。神经元的输出信号可以表示为：

$$A_{i,j} = F \left(\sum_{k=1}^n W_{i,j,k} X_k + B_{i,j} \right) \quad (3.1)$$

其中， $A_{i,j}$ 为第 i 个神经元在第 j 层的输出信号， $W_{i,j,k}$ 为第 i 个神经元在第 j 层与第 k 个神经元在第 $j+1$ 层的连接权重， $B_{i,j}$ 为第 i 个神经元在第 j 层的偏置项， F 为激活函数，用于引入非线性变换。常用的激活函数有 sigmoid 函数、反正切 (tanh) 函数和 ReLU(rectified linear unit, 整流线性单元) 函数等。其中 sigmoid 和 tanh 函数呈 S 型曲线，一般来说更适用于二分类问题；而 ReLU 函数则是一种分段线性函数，在多分类问题中具有很不错的表现。图3.1展示了一个简单的神经网络结构，其中包含一个输入层、两个隐藏层和一个输出层。

神经网络在训练中通常采用反向传播算法，该算法通过计算并降低损失函数的梯度来更新连接权重。损失函数为训练中最重要的部分，其选择几乎决定了模型训练的效率 and 效果。其功能主要为量化预测值与真实值之间的差距，常见的损失函数包括均方误差

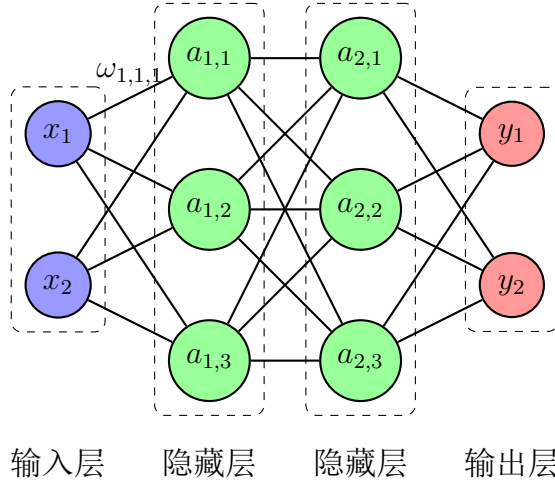


图 3.1: 神经网络基本结构的示意图, 这里包含输入层、两个隐藏层和输出层, 每个隐藏层的神经元都被连接到前一层的所有神经元。最后的输出层将隐藏层的输出转换为最终的预测结果, 在训练过程中, 最终的输出结果会与真实值进行比较, 从而计算损失函数。

和交叉熵等。在模型的训练过程中, 我们通常使用梯度下降算法不断迭代, 从而做到优化这些权重, 进而可以使损失函数被最小化并找到最优参数, 其数学本质为参数空间的最速下降过程:

$$\theta = \arg \min_{\theta} \mathcal{L}(f_{\theta}(x), y) \quad (3.2)$$

其中, θ 为神经网络的参数, \mathcal{L} 为损失函数, $f_{\theta}(x)$ 为神经网络的预测函数, y 为真实值。

上面介绍的神经网络是属于前馈神经网络。基于前馈网络的深度学习模型有很多类型, 其中最常见包括卷积神经网络 (CNN, convolutional neural network) 和循环神经网络 (RNN, recurrent neural network)。CNN 最初被设计用于图像处理任务, 其核心思想是通过卷积层自动提取图像的局部空间特征, 并利用池化层进行特征降维和抗干扰。卷积层能够有效捕捉图像中的边缘、纹理等低级特征, 如果我们把网络层数加深加多, 还能更有效地逐步提取更复杂的抽象特征。池化层则通过下采样操作减少特征图的尺寸, 从而降低模型参数量和计算复杂度, 同时有助于缓解过拟合问题。相比之下, 循环神经网络 (RNN) 则专为处理序列数据而设计。RNN 通过在时间步之间传递隐藏状态, 实现对序列中前后依赖关系的建模。为了解决传统 RNN 在长序列训练中易出现的梯度消失或爆炸问题, 研究者提出了 LSTM (long short-term memory, 长短时记忆)^[10] 或 GRU (gated recurrent unit, 门控循环单元)^[11] 这样的方法, 特别是用来解决序列中长距离依赖的问题。虽然卷积神经网络和循环神经网络都是深度学习的重要部分, 但传统的

RNN 在处理长序列时常效率不高，还容易遇到梯度消失或爆炸的问题。因此，除了 LSTM 和 GRU 这些改良的 RNN 之外，后续介绍的 Transformer 模型也在广泛应用中。

3.2 Transformer

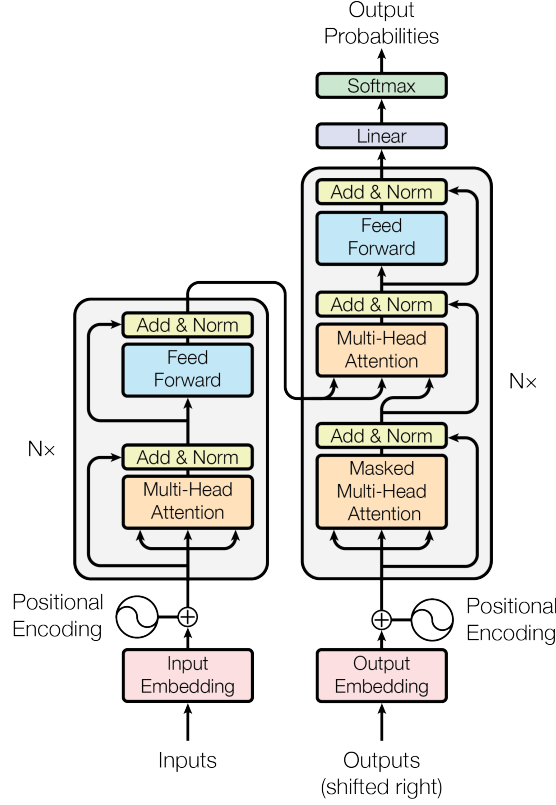
Transformer 是一种基于自注意力机制的神经网络模型，最早由 Google 在 2017 年提出^[12]。这个模型的最大特点是利用自注意力机制，能够捕捉序列中不同位置之间的关系，因此特别擅长处理序列数据，比如翻译、文本生成等。整个 Transformer 由两个主要部分组成：编码器和解码器。编码器的任务是把输入序列变成一个包含上下文信息的向量，解码器则根据这个向量和之前生成的内容，逐步生成输出序列。这两部分都是由多个相同的层叠加而成，每一层都包含多头注意力机制和前馈神经网络。编码器和解码器之间会通过交叉注意力连接，让模型更好地理解输入和输出的关系。具体来说，编码器的输入是一个序列，经过多次注意力和前馈网络后，输出一个总结整个输入的上下文向量。而解码器除了会用到这个上下文向量，还会结合之前生成的内容，经过层层处理，预测下一步的输出。最终，解码器的输出经过线性变换和 Softmax 函数，就能得到每个位置对应的概率分布。接着，可以用采样或贪心搜索等方法，从这些概率中生成最终的输出序列。最后，图3.2 展示了 Transformer 的整体架构。

3.2.1 注意力机制

注意力机制是一种能够动态分配不同输入位置权重的方法，这个机制主要用于建模并量化序列中各个元素之间的关系。这个机制的核心思想是根据输入序列中各位置之间的相关性，为每个位置分配不同的注意力（权重），从而生成包含全局信息的上下文表示。更具体的来说，注意力机制通常包括以下步骤：首先计算查询（Query）与键（Key）之间的相似度，得到注意力权重^[12]：

$$\text{Attention} = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) \quad (3.3)$$

其中， Q 为查询 (Query) 矩阵， K 为键 (Key) 矩阵， d_k 为键矩阵的维度。然后利用这些权重对值 (Value) 进行加权求和，形成上下文向量；最后将上下文向量与原始输入结合，作为后续网络层的输入。通过这种方式，模型能够灵活地调整，从而寻找出与当前任务最相关的信息，有效提升对长序列数据的建模能力。


 图 3.2: Transformer 模型的基本结构示意图^[12]

上面分析的注意力机制被称为“缩放点积注意力 (Scaled dot-product attention)”，不过我们从图3.2可以看出，进行应用的是“多头注意力 (Multi-head attention)”。这是由多个缩放点积注意力经过投影 h 次然后经过 d_k , d_k 和 d_v 并行运算最后叠加而成的。这一机制使得模型可以结合多个不同投影子空间的表现，从而获得更高精确度的预测。为这两种注意力机制的示意图由图3.3给出，其中缩放点积注意力由公式3.3，而多头注意力用公式表征如下^[12]:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O \quad (3.4)$$

$$\text{其中 } \text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (3.5)$$

$$(3.6)$$

其中这些投影为参数矩阵 $W_i^Q \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $W_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$ and $W^O \in \mathbb{R}^{hd_v \times d_{\text{model}}}$.

总而言之，Transformer 模型通过其核心的自注意力机制，特别是多头注意力变体，有效地捕捉了序列数据中的长距离依赖关系。其编码器-解码器架构，结合位置编码和前




图 3.3: 左图为缩放点积注意力，右图为多头注意力由多个并行运行的缩放点积注意力层组成。^[12]

馈网络，使其在序列到序列任务中取得了显著成功，并成为现代深度学习模型的重要基石。

3.3 深度学习中的不确定性分析

深度学习模型在各种领域展现出了强大的预测能力，然而对这些模型预测结果的不确定性进行量化是一个重要且具有挑战性的问题。不确定性量化 (Uncertainty Quantification, UQ) 旨在评估和表征深度学习模型预测的可靠性和置信度。在实际应用中，了解模型预测的不确定性对于决策制定、风险评估和模型解释至关重要。

在深度学习领域，不确定性可分为认知不确定性 (模型不确定性) 和随机不确定性 (数据不确定性)。^[13] 前者源于模型参数的不确定性，可通过贝叶斯方法量化；后者源于数据本身的噪声或随机性，通常通过概率分布建模。深度学习中的不确定性量化方法主要包括 BNN (Bayesian neural network, 贝叶斯神经网络)、深度集成方法^[14]和 MC(Monte Carlo, 蒙特卡洛) dropout 等技术。这些方法使我们能够对模型预测结果提供可靠的不确定性估计，从而增强模型在实际应用中的可靠性和可解释性。

3.3.1 BNN

BNN 的核心思想是将神经网络的权重 (ω) 和偏置视为概率分布，而不是固定的点估计值，如图3.4所示。其目标是根据观测数据 D 推断权重的后验分布 $p(w|D)$ 。对于新

的输入 x^* ，BNN 的预测是通过对所有可能的权重配置进行边缘化 (或积分) 得到的，即进行贝叶斯模型平均：^[13]

$$p(y^*|x^*, D) = \int p(y^*|x^*, w)p(w|D)dw \quad (3.7)$$




图 3.4: 贝叶斯神经网络的基本结构示意图^[15]

由于精确计算后验分布通常是不可行的，我们一般需要采用一些近似推断方法，例如 VI (Variational Inference, 变分推断)，MCMC (Markov Chain Monte Carlo, 马尔可夫链蒙特卡洛)，拉普拉斯近似等。

对于 VI，我们使用一个简单的、可处理的概率分布 $q(\theta)$ (例如，均值场高斯分布) 来近似真实的后验分布 $p(w|D)$ ，通过最小化它们之间的 Kullback-Leibler 散度^[16]来优化近似分布的参数。VI 在计算上通常比 MCMC 更高效，但其结果依赖于近似分布的选择。

对于 MCMC，我们通过构建马尔可夫链来从后验分布中采样。MCMC 一般被认为能够提供更加精确的估计，但计算成本非常高，尤其对于参数量巨大的深度神经网络。

对于拉普拉斯近似，我们将后验分布近似为以最大后验概率 (MAP) 估计为中心的高斯分布，其协方差矩阵由损失函数的 Hessian 矩阵的逆给出。

BNN 能够自然地捕捉认知不确定性 (通过权重分布的方差体现)。如果模型被设计为预测输出的分布参数 (例如，预测高斯分布的均值和方差)，则也可以捕捉偶然不确定性。一些研究工作尝试利用 BNN 来分离统计不确定性和系统不确定性。一方面，BNN 提供了严谨的贝叶斯框架；有潜力产生良好校准的不确定性估计；能够捕捉模型参数之间的复杂相关性。不过另一方面，BNN 计算成本高昂 (尤其是 MCMC)；结果可能依赖于先验分布的选择；而 VI 的近似质量可能受限；训练过程可能不稳定。

3.3.2 MC Dropout

Dropout 是一种常用的正则化技术，在训练过程中以一定概率随机“丢弃”（即设置为零）神经元的输出。MC dropout 将这一过程扩展到测试（推断）阶段：对同一个输入样本，通过多次随机前向传播，每次使用不同的随机 Dropout 掩码（mask），从而得到一组不同的预测结果，如图3.5所示。




图 3.5: MC dropout 的基本结构示意图^[15]

MC dropout 主要捕捉认知不确定性（模型不确定性），这种不确定性体现在不同 dropout 掩码下预测结果的变化性上。它可以与预测偶然不确定性的模型结合使用。不过相比 BNN，MC dropout 实现更简单，可以方便地应用于已经使用 Dropout 进行正则化的现有网络架构；计算成本相比 BNN 更低。然而，其贝叶斯近似的质量可能有限；对于大型复杂模型，其不确定性估计可能校准不佳或不足；而且其性能（包括 UQ 质量）依赖于 dropout 率的选择和网络结构；不确定性的解释可能不够直接。

3.3.3 深度集成

深度集成是训练多个（N 个）结构相同（或相似）但参数独立的神经网络模型。^[14] 这些模型通常使用不同的随机权重初始化，有时也使用不同的训练数据子集（例如通过 bootstrapping，如图3.6所示）。进行训练。最终预测结果通过组合 N 个模型的输出得到（例如，对回归任务取均值，对分类任务取平均概率），而不确定性则由模型预测结果之间的差异（例如方差）来估计。




图 3.6: 深度集成训练中 Bootstrapping 的基本结构示意图^[15]

该方法主要通过模型多样性来捕捉认知不确定性。可以与能够预测偶然不确定性的模型 (例如, 预测输出分布的均值和方差) 结合, 使用集成预测的方差来估计认知不确定性部分。

深度集成概念简单直观; 在许多基准测试和实际应用中, 常常能达到顶尖的预测精度和良好的校准性能; 模型训练过程可以并行化; 但是训练和推断的计算成本很高 (需要训练和运行 N 个模型), 需要大量的存储空间; 同时我们还需要确保集成成员具有足够的多样性; 仅仅通过集成预测的差异来估计不确定性, 缺乏严格的数学基础来保证其能可靠地同时涵盖偶然和认知不确定性。

总而言之, 不确定性量化在深度学习模型的应用中具有重要意义, 有助于提升模型的可靠性和决策质量。选择合适的 uncertainty 量化方法需要在计算成本和精度之间进行权衡。

3.4 本章小结

本章首先介绍了一些深度学习的基础知识, 从神经网络的基本结构、神经元、激活函数和训练过程等等入手, 同时说明了前馈神经网络的基本原理, 并简要提了 CNN 和 RNN 等常见变种。随后, 我们重点介绍了在序列数据处理中具有优秀的表现并且获得广泛认可的 Transformer 模型, 之后详细解释了其核心的自注意力机制, 特别是缩放点积注意力和多头注意力。最后, 本章深入探讨了深度学习中的不确定性量化问题, 先对

认知不确定性和随机不确定性进行了概念的解释和区分，并详细介绍了三种主流的不确定性量化方法：BNN、MC Dropout 和深度集成。对每种方法的原理、优缺点和适用场景进行了分析，强调了不确定性量化对于提升模型可靠性和可解释性的重要性。

第四章 SNO+ 实验

SNO+(Sudbury Neutrino Observatory+) 实验是一个位于加拿大安大略省的 SNO-LAB (Sudbury Neutrino Observatory Laboratory, 萨德伯里实验室) 的实验。该实验的低背景, 高分辨率, 很适合开展多方面的中微子研究, 例如反应堆中微子, 太阳中微子, 超新星中微子等。SNO+ 实验的主要科学目标是探测极为罕见的无中微子双贝塔衰变 ($0\nu\beta\beta$)。为实现这一雄心勃勃的目标, SNO+ 分阶段在一个直径 12 米的丙烯酸容器中先后装载了纯水 (2017-2019 年), 780 吨液体闪烁体 (2019-2024 年), 并计划向其中加入约 1.3 吨的同位素 ^{130}Te (碲-130)(预计 2025 年开始)^[3]。

这一章主要介绍 SNO+ 实验, 4.1 节简要介绍了 SNO+ 实验的物理目标, 4.2 节简要介绍了 SNO+ 实验的实验装置, 4.3 节简要介绍了 SNO+ 实验中的部分背景事件。

4.1 物理目标

SNO+ 实验的主要科学目标是使用 ^{130}Te 探测一种极为罕见的物理现象——无中微子双贝塔衰变 ($0\nu\beta\beta$)。这一现象在 2.4 节中已经介绍过了。如果观测到这一现象, 将对中微子物理和基本粒子理论产生深远的影响。目前根据 COURE 实验的结果, 对于 ^{130}Te 的 $2\nu\beta\beta$ 衰变的半衰期为:^[17]

$$T_{1/2}^{2\nu} = 7.71_{-0.06}^{+0.08}(\text{stat.})_{-0.15}^{+0.12}(\text{syst.}) \times 10^{20} \text{ yr} \quad (4.1)$$

End point 能量为:^[18]

$$Q_{\beta\beta} = 2527.518 \pm 0.013 \text{ keV} \quad (4.2)$$

^{130}Te 相对其他同位素具有很多优势, 包括其较高的自然丰度 (34.1%), 以及相对更便宜的价格。这使得我们可以在不进行富集的情况下大批量地投入使用。同时, ^{130}Te 的 $2\nu\beta\beta$ 衰变的半衰期也相对较长, 这使得不可减少的 $2\nu\beta\beta$ 背景事件被压低了。

除了 $0\nu\beta\beta$ 之外, SNO+ 实验还可以用于其他的中微子研究, 例如低能量的太阳中微子, 地球中微子, 反应堆中微子等。SNO+ 探测器同时也可以作为一个超新星中微子监测器。

4.2 SNO+ 实验装置

SNO+ 实验的选址位于地下 2.1km 的 SNOLAB。等效水深约为 6010m，可以有效地屏蔽宇宙射线。SNO+ 复用了 SNO 实验的探测器，并进行了升级。SNO+ 探测器的主要结构由一个厚度为 55 mm，直径为 12 m 的球形透明的 AV(acrylic vessel, 丙烯酸容器) 组成, 用来装载 780 吨液体闪烁体, 包括 LAB(linear alkyl benzene, 线性烷基苯) , PPO(2,5-diphenyloxazole, 2,5-二苯基恶唑) 以及 bis-MSB(1,4-bis(2-methylstyryl)-benzene, 1,4-双(2-甲基苯乙烯基) 苯)。AV 由直径 17.8 m 的 PSUP(geodesic steel structure, 测地钢结构) 环绕, PSUP 内设有 9362 个带有低活性玻璃和聚光器的内向型 PMT(photomultiplier tubes, 光电倍增管)。91 个没有聚光器的 PMT 也被安装在朝向探测器外的地方, 以探测来自 子和 PSUP 外部区域的其他光源的光。AV 和 PMT 之间以及包含探测器的其余腔体的体积由 7000 吨超纯水 (UPW) 填充。这个外部水量为来自 PSUP 和空腔墙的 AV 提供了数米的屏蔽, 这两个空腔墙都是外部辐射的来源。如图4.1所示。




图 4.1: 左边是 SNO+ 实验装置的示意图^[3], 右边是 SNO+ 实验装载纯水时内部的照片^[3]

4.3 SNO+ 实验中的背景事件

如果我们要分辨出 $0\nu\beta\beta$ 的微弱信号，那么准确的背景分析至关重要。从图2.2中，我们可以看出，最终我们要探测的是后面 $0\nu\beta\beta$ 的峰，也即 $0\nu\beta\beta$ ^{130}Te 的 Q 值。

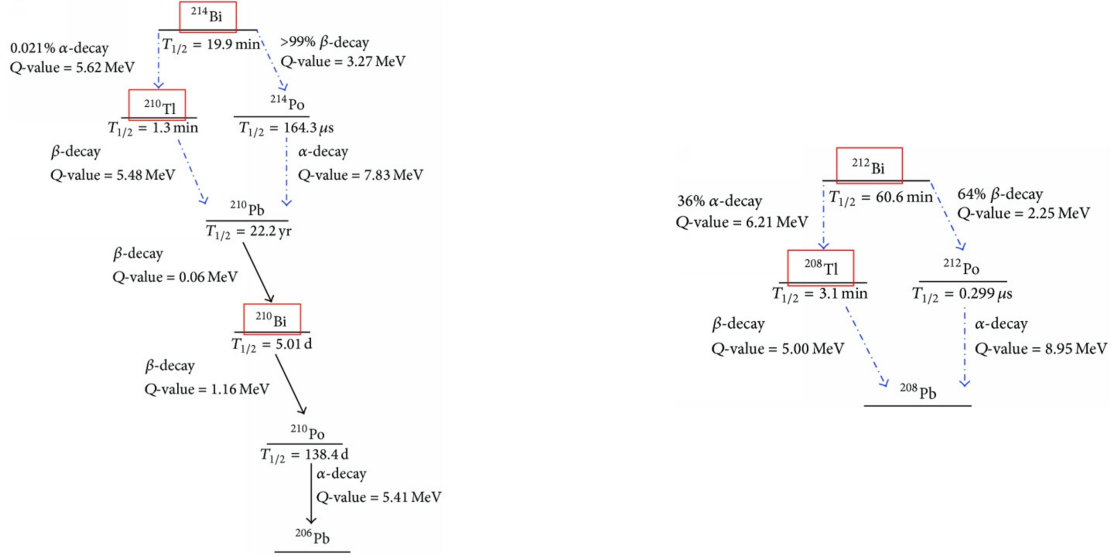


图 4.2: SNO+ 实验中 ^{214}Bi - ^{214}Po 和 ^{212}Bi - ^{212}Po 衰变的 Q 值^[3]

对于这一同位素，从表2.1中我们知道，其 Q 值约为 2.5MeV。故 SNO+ 中的背景分析需重点关注其 $(-0.5\sigma, 1.5\sigma)$ 内，即大约 2.47-2.69MeV 的事件。重点关注的背景事件有 ^{214}Bi - ^{214}Po ， ^{212}Bi - ^{212}Po ， ^8B 太阳中微子等。


从 NNDC(National Nuclear Data Center, 国家核数据中心)，以及图4.2中 ^{212}Bi - ^{212}Po 和 ^{214}Bi - ^{214}Po 衰变的 Q 值，我们可以看到，图中 Q 值并不位于 2.5MeV 附近，然而由于量子淬灭效应，使得实际在 SNO+ 探测器中探测到的 Q 值会偏低。^[19] 这样，这个衰变 ($\beta - \alpha$ 衰变中的 α 衰变) 的 Q 值会落在这一范围内。

而对于 ^8B 太阳中微子，我们从图4.3中可以看到，根据标准太阳模型，太阳光谱中 ^8B 中微子能谱的分布覆盖了 0.1-15MeV 的范围，当然也包括了 2.5MeV 附近的范围。我们可以看到， ^8B 中微子这一能量附近的流强约为 $10^4\text{cm}^{-2}\text{s}^{-1}(100\text{keV}^{-1})$ 量级。

在所有 ^8B 太阳中微子的衰变道中，这一能量附近的 ^8B 中微子的衰变道中，只有弹性散射 (ES, elastic scattering) 会发生，即

$$\nu_e + e^- \rightarrow \nu_e + e^- \quad (4.3)$$

故探测到的是一个单信号 (即电子的信号)。因此 ^8B 太阳中微子也是一个重要的背景事


 图 4.3: 太阳中微子能谱^[8]

件。

4.4 小结

本章首先介绍了 SNO+ 实验的基本情况，包括其地理位置、发展阶段等。接着，详细阐述了 SNO+ 的物理目标，不仅包括核心的 $0\nu\beta\beta$ 探测，还涵盖了太阳中微子、地球中微子、反应堆中微子以及超新星中微子等其他研究方向，并解释了选择 ^{130}Te 作为目标同位素的优势。随后，本章描述了 SNO+ 实验的装置，包括其深地实验室的位置、探测器的主要组成部分。最后，我们讨论了 SNO+ 实验中对 $0\nu\beta\beta$ 探测构成挑战的主要背景事件，其中重点分析了 ^8B 太阳中微子弹性散射事件，以及 ^{214}Bi - ^{214}Po 、 ^{212}Bi - ^{212}Po 衰变链，这些事件的能量可能落在感兴趣的区域内，需要精确识别和扣除。这些背景事件在下一章都会成为我们在机器学习中需要用到的数据集。

第五章 SNO+ 实验的位置重建以及不确定性量化

探测器中收集到的原始数据无法直接拿来物理分析，这些数据需要经过一系列的计算，才能拿到后续所需要的物理量。例如经过计算拿到了衰变顶点的位置，方向，能量，粒子类型等，并进行分析。这一计算过程我们称之为重建。

这一章首先5.1节介绍 SNO+ 探测器中传统的位置重建方法，即最大似然法。接着在5.2节介绍深度学习在 SNO+ 探测器中的重建方法，并给出两者结果的比较。同时也会给出两者重建结果不确定性的估计。

5.1 SNO+ 探测器中传统的位置重建方法

在 SNO+ 探测器中，传统的位置重建方法主要是基于 MLE (Maximum likelihood estimation, 最大似然估计) 的。一般我们通过 PMT 的时间和位置信息来进行重建。可能后期还会加入其他的信息，例如 PMT 的积分电荷等。SNO+ 实验中应用的 MLE 方法是基于一个假设，即 PMT 接收到了一个内部电子的光子信号^[20]。虽然这个假设可能不是一直成立，不过我们还会用其他的方法来分辨粒子类型。

更严谨地说，如果我们想确定一个事件的位置，我们会把一个基于时间残差的似然函数在每个 PMT 上最大化。时间残差 $T_{res,i}$ 的定义为：

$$T_{res,i} = T_{PMT,i} - T_{fit} - T_{transit}(\vec{x}_{PMT,i}, \vec{x}_{fit}) \quad (5.1)$$

其中 $T_{PMT,i}$ 为 PMT 被击中的时间， T_{fit} 为事件的拟合时间， $T_{transit}$ 为光子在 PMT 和事件之间传播的时间。一般我们认为光子沿直线传播，所以 $T_{transit}$ 可以表示为：

$$T_{transit}(\vec{x}_{PMT,i}, \vec{x}_{fit}) = \frac{\|\vec{x}_{PMT,i} - \vec{x}_{fit}\|}{c_{avg}} \quad (5.2)$$

其中 c_{avg} 为光子在液体闪烁体中的平均速度。不过在 SNO+ 中，光子需要穿过液体闪烁体，AV, UPW 和 PMT 的玻璃等介质，才能到达 PMT 的收集装置。

$T_{res,i}$ 的分布一般服从正态分布，其均值为 0，方差为 σ_i^2 。所以似然函数可以表示为：

完整的 PDF (Probability density function, 概率密度函数) 由于考虑了反射，PMT 本身的噪声以及各种其他的效应，更加的复杂。结果为一个具有长尾巴并且有多个峰分布。这个结果是从模拟和刻度中得到的^[20]。

T_{fit} 和 x_{fit} 是我们需要拟合的参数。我们可以通过最大化似然函数来得到它们的值。

$$\mathcal{L}_{vertex} = \prod_{i=1}^{Nhits} P(T_{res,i}) \quad (5.3)$$

其中 Nhits 是 PMT 被击中的数目。不过一般来说，我们不会直接最大化似然函数，而是最小化负对数似然函数：

$$-\log(\mathcal{L}_{vertex}) = -\sum_{i=1}^{Nhits} \log P(T_{res,i}) \quad (5.4)$$

更具体一点，SNO+ 使用的是 Powell 算法^[21]来最小化负对数似然函数。Powell 算法是一种无导数的优化算法，它通过迭代地调整参数来找到函数的最小值。该算法使用了一个线性组合的搜索方向，并在每次迭代中更新参数。Powell 算法的优点是它不需要计算梯度，因此适用于那些难以计算导数的函数。例如 SNO+ 目前重建所用的 PDF。当然，不止传统算法，神经网络在训练时的梯度下降算法的思想与 Powell 算法比较相似。

目前 SNO+ 实验所使用的重建方法涉及各种算法的先后结合^[22]。主要算法如5.4 一样最小化负对数似然函数来确定事件位置。然而，尽管最大化似然函数是该过程中的第一步，由于需要拟合的参数必须初始化为某个值，有几个算法是事先运行的。这个被初始化的值通常称为种子¹。与神经网络反向传播的情况一样，初始值对是否能准确重建有很大的影响。

5.2 深度学习在 SNO+ 探测器中的位置重建方法

上面我们简要介绍了传统的位置重建方法，我们可以看到，传统的方法需要对 PMT 的响应进行建模，并且对噪声和背景有较强的依赖性。在液体闪烁体探测器中，传统方法对于直接接收的光子² 和非直接接收的光子³ 的分辨能力不强。而非直接接收的光子的产量极高，而深度学习方法则是基于数据驱动的方法，通过对大量实验数据的学习，

¹我们使用的初始化算法基于只需要 4 个 PMT 击中就可以解析地计算事件的位置和时间的原理。根据5.1, $T_{res,i}$ 设置为零时有四个参数需要拟合，所以只需要四次命中 PMT 的信息。当然，在实际应用中，计算位置和时间的准确性取决于选择哪四个 PMT，光子从事件到击中 PMT 的路径，以及与击中时间相关的噪声。随后重复 4000 次并取平均

²这里指的是带电粒子产生的切伦科夫光的光子，同时该光子还要满足没有被液体闪烁体吸收并再次发射，且没有被 PMT 的玻璃外壳反射。

³这里指的不只是上述切伦科夫光子，更多的包括了液体闪烁体发射的光子，其产额远大于产生的切伦科夫光的光子。

可以捕捉到一些传统方法捕捉不到的信息，例如上面提到的直接接收的光子和非直接接收光子的分类以及后续对直接接收的光子的回归，从而能更好的进行事件的位置重建，以及更重要的方向重建，具有更好的适应性和鲁棒性。

接下来我们介绍深度学习在 SNO+ 探测器中的位置重建方法。前面3.1节中介绍了神经网络的基础架构，以及 CNN 和 RNN，这两种神经网络在粒子物理实验的重建工作中都有使用。我们使用的是在3.2节中介绍的 Transformer 模型的部分架构。得益于 Transformer 模型的自注意力机制，我们可以在输入数据中捕捉到长距离的依赖关系，从而更好地建模复杂的事件特征。

5.3 数据集

我们在4.4节中提到，我们使用了 SNO+ 实验的模拟数据集来训练和测试模型。主要为了保证模型的泛化能力，我们使用了不同的能量范围和位置的数据集。主要使用了 8B 衰变道的太阳中微子数据。这里与之前 SNO+ 组内使用的模拟数据不同的是，我们额外使用了不同探测器状态的模拟，以此来保证模型的泛化能力。¹而 SNO+ 合作组使用的 RAT (Reactor analysis tool, 反应堆分析工具) 软件提供的 MC 框架中提供了完整的 run-by-run 的模拟数据设置。也就是说，模拟可以完整包含对应 run number 的所有 PMT 状态信息。这大大提升了训练出来的模型的鲁棒性，使得我们在预测时，即使在不同的探测器状态下也能有较好的效果。

我们的模拟使用的是 SNO+ 中液体闪烁体阶段的探测器。其液体闪烁体配方为 LAB+PPO+bis-MSB。在模拟完成后，我们提取对于位置重建有用的信息，如 PMT 的时间和位置，以及真实的事件位置，能量等。我们使用了大约 10^6 个事件来训练模型，分为训练集和测试集。训练集和测试集的比例为 70% 和 20%。

5.4 位置重建模型架构

我们采用基于 Transformer 的模型进行位置重建。该模型主要包括特征嵌入、Transformer 编码器和输出层。

¹在 SNO+ 实验中，探测器在不同的时间有不同的状态，例如在某些时候，探测器的某些 PMT 会关闭，或者会进行维护，这些状态会影响 PMT 的响应。

5.4.1 输入与嵌入

模型的输入是每次事件中被触发的光电倍增管 (PMT) 的命中序列。每个命中包含时间、PMT ID 及其三维坐标 (x, y, z) 。这些原始特征首先被转换 (嵌入) 为固定维度的向量。连续特征 (时间、坐标) 通过线性层处理，分类特征 (PMT ID) 通过查找表转换。所有特征的嵌入向量被拼接起来，形成每个命中的初始表示。

5.4.2 Transformer 编码器

嵌入后的命中序列被送入 Transformer 编码器。在进入编码器之前，会添加位置编码以保留命中顺序信息。编码器由多个堆叠的注意力模块 (Attention Block) 组成。每个模块包含：

- **多头自注意力 (Multi-Head Self-Attention)**：捕捉序列中不同 PMT 命中之间的复杂关联。
- **前馈神经网络 (Feed-Forward Network)**：对注意力层的输出进行进一步处理。

每个模块都使用了层归一化 (Layer Normalization) 和残差连接 (Residual Connection) 来稳定训练和提升性能。

5.4.3 输出层与损失函数

编码器处理完整个序列后，输出每个命中位置的上下文感知表示。为了得到代表整个事件的单一向量，我们对序列输出进行平均池化 (考虑了序列填充的掩码)。最后，这个池化后的向量经过一个线性层，输出预测的事件顶点三维坐标 (x, y, z) 。

模型训练采用加权的均方误差 (MSE) 损失函数。该损失函数会根据预测位置与真实位置的距离误差来调整每个样本的权重，目的是降低特别大的误差 (异常值) 对模型训练的影响，或根据需要增加其影响。

5.4.4 模型训练

模型训练采用流式处理和分块方法处理大型数据集。主要流程如下：

1. **初始化:** 配置训练参数、日志、计算设备 (CPU/GPU) , 加载 PMT 位置信息, 并构建特征嵌入层和 GPT 回归器模型。定义加权均方误差损失函数、Adam 优化器和余弦退火学习率调度器。
2. **数据处理:** 训练数据 (ROOT 文件) 被分成多个块 (chunks) 以适应内存。对每个块:
 - 加载事件数据, 进行筛选 (如命中数、能量、位置范围)、排序和坐标转换。
 - 将块内事件随机划分为训练集、验证集和测试集。测试集事件被累积起来用于最终评估。
3. **训练与验证循环:**
 - 在每个训练轮次 (epoch) 中, 模型依次处理所有数据块。
 - 对每个块的训练集部分, 模型通过小批量梯度下降进行训练, 计算损失并更新参数。
 - 对每个块的验证集部分, 模型在评估模式下计算损失, 以监控性能。
 - 显存会定期清理以处理大数据。
4. **模型选择与早停:**
 - 每个轮次结束后, 计算平均训练和验证损失。
 - 根据验证损失更新学习率。
 - 如果当前验证损失优于历史最佳, 则保存模型状态。
 - 若验证损失连续多个轮次没有改善 (达到预设耐心值) , 则触发早停机制, 提前结束训练。
5. **最终评估与输出:**
 - 训练结束后, 加载性能最佳的模型。
 - 在累积的测试集上进行最终评估, 计算预测位置与真实位置的距离误差等指标, 并与传统方法¹进行比较。

¹这里使用的是 RAT 中集成的闪烁体拟合 “scintFitter” 中内嵌的重建方法

- 生成损失曲线图、预测性能对比图 (如误差分布、分辨率随能量/命中数变化)，并将测试集的预测结果、真实值等信息保存到新的 ROOT 文件中。

这种方法允许在有限的内存资源下训练大型数据集，并通过验证集监控、早停和学习率调度来优化训练过程和模型性能。

5.5 深度学习位置重建结果

从图5.1，中我们可以看到，我们利用 ^8B 太阳中微子数据的验证集进行位置重建，并选择了三维空间中预测的坐标与真实坐标之间的距离作为评价指标。从图中我们可以看到，目前经过短暂的小数据集训练，深度学习模型的重建结果基本达到了传统的重建方法的精度，同时从图5.2和图5.3中，我们可以看到，在不同能量范围和探测器内，深度学

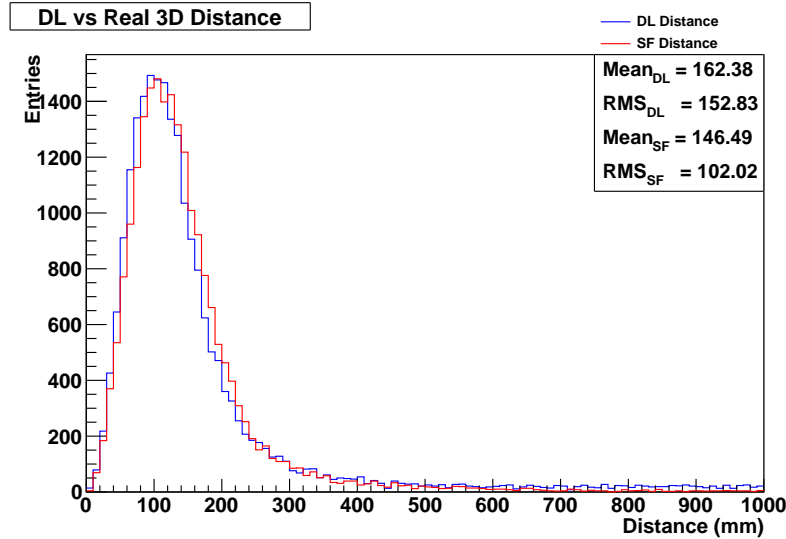


图 5.1: 深度学习和传统方法位置重建结果

习模型的重建结果也基本与传统方法持平。在探测器边缘位置深度学习方法的重建结果略优于传统方法。

而传统的重建方法在低能量范围内的重建结果较差，在能量较高时，重建结果较好。这说明深度学习模型在不同能量范围内的重建结果都比较稳定。

5.6 位置重建不确定性的量化

上一节中我们介绍了 SNO+ 探测器中位置重建的深度学习方法，并给出了模型的架构和训练方法。在本节中，我们将之前提到的理论投入实际应用，介绍如何具体量化这

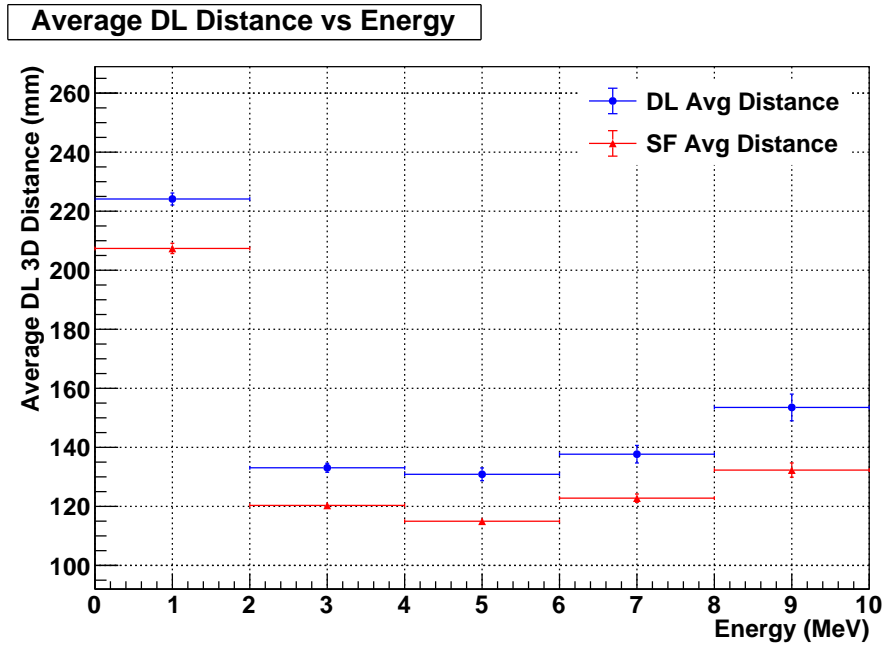


图 5.2: 深度学习和传统方法位置重建精度随能量变化

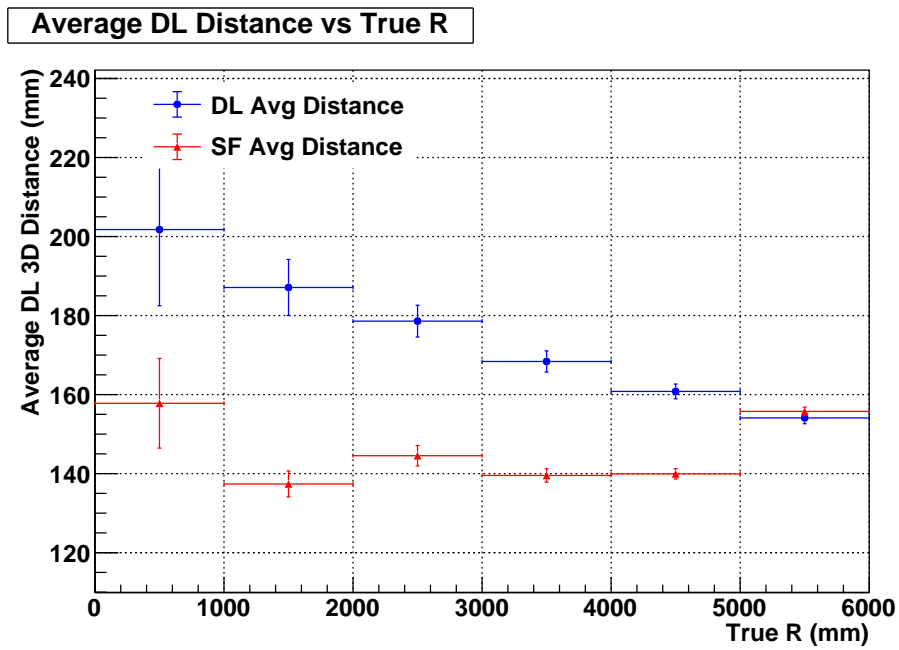


图 5.3: 深度学习和传统方法位置重建精度随位置变化

一深度学习位置重建模型的不确定性。

5.6.1 粒子物理实验中不确定性的估计

在正式开始量化深度学习模型的不确定性之前，我们首先要明确粒子物理实验领域和深度学习领域 UQ (Uncertainty Quantification, 不确定性量化) 的类型以及两者的区别和联系^[8]。

在3.3节中,我们了解到,深度学习领域中,不确定性常被区分为偶然不确定性 (aleatoric uncertainty) 和认知不确定性 (epistemic uncertainty)。而它们与物理学中使用的概念并非完全相同,存在视角上的差异。

首先,在数据收集与不确定性缩减方面,物理学通常关注在固定的实验设计下,通过增加数据量来减少不确定性。在这种情况下,统计不确定性 (类似于偶然不确定性) 会随着数据量的增加而减小,而系统不确定性 (类似于认知不确定性) 通常保持不变,除非改进实验设计或进行更精确的校准。相比之下,深度学习领域更侧重于通过收集不同类型的数据来改进模型本身,从而减少认知不确定性。他们所认为的“不可约减”的偶然不确定性,是指在给定模型下的固有随机性。这种差异并非根本矛盾,而是反映了不同领域关注点的侧重不同。

其次,“模型”的含义也有所不同。在物理学中,“模型”通常指代底层的物理过程或通过模拟体现的探测器响应模型。系统不确定性或认知不确定性与对这些物理模型的理解程度密切相关。而在机器学习领域,“模型”通常指训练得到的函数,例如神经网络。认知不确定性常与训练后模型参数 θ 的不确定性相关联,这种不确定性可以通过收集更多的训练数据来减少。这部分是因为机器学习任务通常对数据生成过程 (如图像分类、自然语言处理) 的先验物理知识较少。

在与物理学 (特别是计算机模拟) 联系更紧密的 UQ 领域,术语的划分更为细致,有助于减少歧义。UQ 领域通常区分以下几种不确定性来源: 参数不确定性,例如模型中扰动参数 (nuisance parameters) 的不确定性; 结构不确定性,指模型本身与现实不符 (mismodelling) 导致的不确定性,例如在 SNO+ 中 MC 模拟与现实中探测器的实际情况的差异引起的不确定性; 算法不确定性,源于数值计算方法引入的误差,例如5.1节中提到的 SNO+ 实际使用的 Powell 算法引入的不确定性; 实验不确定性,包括实验分辨率限制和统计涨落导致的不确定性; 以及插值不确定性,这是由于计算资源限制,在不同参数点之间进行插值而引入的不确定性。

5.6.2 在深度学习中量化不确定性的方法

深度学习中的不确定性分析方法在3.3节中已经介绍过了，我们这里使用的是 MC Dropout 方法来量化深度学习模型的不确定性。量化的模型是在5.4节中介绍的基于 Transformer 的模型。

对于 MC Dropout 方法，我们在训练时使用了 Dropout 层，并在测试时使用了多次不同 Dropout 并进行前向传播来获得模型的预测分布。

5.6.3 不确定性量化结果

我们使用了 MC Dropout 方法对5.4节中描述的 Transformer 模型进行了不确定性量化。对于 MC Dropout，我们在训练期间使用的 Dropout 层在推理阶段保持启用状态。通过对同一输入事件进行 N 次前向传播（每次使用不同的 Dropout 掩码），我们得到了 N 个不同的位置预测 $\{\hat{x}_1, \dots, \hat{x}_N\}$ 。最终的预测位置 \hat{x} 是这些预测的平均值，而预测的不确定性则由这些预测的标准差或方差来估计。这种方法估计的不确定性通常被认为是认知不确定性和偶然不确定性的混合。

为了评估不确定性量化的质量，我们主要关注几个方面。首先，一个好的不确定性估计应该与实际的预测误差相关，即当模型预测的不确定性较高时，其预测误差也倾向于较大。我们通过比较预测位置 \hat{x} 与真实位置 \vec{x}_{true} 的距离误差 $\|\hat{x} - \vec{x}_{true}\|$ 来评估这一点。初步结果显示，通过 MC Dropout 方法得到的预测不确定性与实际的预测误差表现出正相关性，表明模型在某种程度上能够识别其预测的置信度。

如图5.4和图5.5所示，我们观察到预测的总不确定性通常在低能量和靠近探测器边缘的区域较高。这符合预期，因为这些区域的可用信息较少或几何效应更复杂，导致重建更具挑战性。

这些量化的不确定性估计对于后续的物理分析至关重要。例如，可以将事件按照其预测不确定性进行加权，或者在进行信号和背景区分时，将具有高不确定性的事件排除或单独处理。通过区分认知不确定性和偶然不确定性，我们可以更好地理解误差的来源：高认知不确定性可能提示需要改进模型或收集更多样化的数据（对应减少模型相关的系统误差），而高偶然不确定性则反映了实验本身的固有局限性（对应统计误差和探测器相关的系统误差）。将这些基于深度学习的不确定性与传统方法（如 MLE 拟合中的参数误差）进行比较，也是未来工作的一个重要方向。此外，未来的工作还应关注不确定性校准（Calibration）。理想情况下，预测的不确定性应准确反映真实的误差水平，例如，




图 5.4: 取样后多次前向传播后的 ΔR 随真实能量的变化趋势示例




图 5.5: 取样后多次前向传播后的 ΔR 随真实径向位置的变化趋势示例

对于预测标准差为 σ 的事件集合，其预测位置的均方根误差 (RMSE) 应接近 σ 。需要通过绘制校准曲线 (比较不同预测不确定性分箱内的平均 RMSE) 来评估校准程度，并对可能存在的过拟合或欠拟合的区域进行调整。

第六章 总结与展望

6.1 总结

本论文围绕大型液体闪烁体探测器 SNO+ 实验中的事件顶点重建问题，深入研究了基于深度学习的方法，并着重探讨了其预测结果的不确定性量化 (UQ)。

首先，论文系统回顾了中微子物理学的基本知识，包括中微子的发现、振荡现象、质量问题以及双贝塔衰变 (特别是无中微子双贝塔衰变 $0\nu\beta\beta$)，为理解 SNO+ 实验的物理目标奠定了基础。接着，介绍了深度学习的基本概念，从神经网络基础架构到 CNN、RNN，并重点阐述了在序列数据处理中表现优异的 Transformer 模型及其核心的自注意力机制。同时，论文详细讨论了深度学习中的不确定性量化问题，区分了认知不确定性和偶然不确定性，并介绍了 BNN、MC Dropout 和深度集成等主流 UQ 方法。

随后，论文详细介绍了 SNO+ 实验的概况，包括其科学目标 (探测 ^{130}Te 的 $0\nu\beta\beta$)、实验装置以及主要的背景来源 (如 ^8B 太阳中微子， ^{214}Bi - ^{214}Po 和 ^{212}Bi - ^{212}Po)。在此基础上，论文对比了 SNO+ 中传统的基于 MLE 的位置重建方法和基于深度学习的方法。

本文的核心工作包括：设计并实现了一个基于 Transformer 架构的深度学习模型，用于 SNO+ 实验中 ^8B 太阳中微子事件的顶点位置重建，该模型能够利用 PMT 的时间、位置等信息作为输入，通过自注意力机制有效捕捉被击中 PMT 之间的复杂关联。利用包含不同探测器运行状态的 SNO+ 模拟数据对模型进行了训练和评估，结果表明（如图5.1所示），该深度学习模型在位置重建性能上基本达到了传统的 MLE 方法。此外，论文应用了 MC Dropout 对所开发的 Transformer 重建模型进行了不确定性量化，系统分析了其随能量、径向位置等物理量的变化趋势。

总之，本研究成功将 Transformer 深度学习模型应用于 SNO+ 事件重建，并对其进行了不确定性量化，验证了该方法在提升重建精度和提供可靠性评估方面的潜力。

6.2 展望

尽管本研究取得了一定的进展，但仍有许多地方需要进一步的探索和改进。

首先，在模型优化与扩展方面，我们可以尝试采用更好的神经网络架构，并将 PMT

电荷信息等更多特征加入到模型输入里面来提升重建的精度，这个方法也可以推广到能量重建、粒子鉴别等其他任务。

在不确定性量化方面，有必要对不确定性估计进行更严格的校准，比较更多 UQ 方法（如 BNN 的变分推断），并深入研究如何将量化的不确定性有效应用于后续的物理分析，例如在背景抑制、信号提取或系统误差评估等等。此外，未来还需将训练好的模型和 UQ 方法应用于 SNO+ 的真实实验数据，检验其在实际应用中的表现，并尝试去解决模拟与真实数据之间的差异问题。考虑到深度学习模型（尤其是 Transformer 和集成方法）的计算成本较高，我们该需要探索其他方法以提高计算效率，便于在 SNO+ 的数据处理流程中部署。最后，本研究开发的基于 Transformer 的重建和 UQ 方法具有一定的通用性，未来可以探索其在其他大型粒子物理实验中的应用。

通过对上述方向的深入研究，有望进一步发挥深度学习和不确定性量化在粒子物理实验数据分析中的作用，为揭示中微子的奥秘和探索新物理提供更强大的工具。

参考文献

- [1] AHMAD Q R, ALLEN R C, ANDERSEN T C, et al. Measurement of the Rate of $\nu_e + d \rightarrow p + p + e^-$ Interactions Produced by 8B Solar Neutrinos at the Sudbury Neutrino Observatory[J/OL]. Phys. Rev. Lett., 2001, 87:071301. <https://link.aps.org/doi/10.1103/PhysRevLett.87.071301>.
- [2] FUKUDA Y, HAYAKAWA T, ICHIHARA E, et al. Evidence for Oscillation of Atmospheric Neutrinos[J/OL]. Phys. Rev. Lett., 1998, 81:1562-1567. <https://link.aps.org/doi/10.1103/PhysRevLett.81.1562>.
- [3] ANDRINGA S, ARUSHANOVA E, ASAH I S, et al. Current status and future prospects of the SNO+ experiment[J]. Advances in High Energy Physics, 2016, 2016(1):6194250.
- [4] ALBANESE V, ALVES R, ANDERSON M, et al. The SNO+ experiment[J]. Journal of Instrumentation, 2021, 16(08):P08059.
- [5] COWAN C L, REINES F, HARRISON F B, et al. Detection of the Free Neutrino: a Confirmation[J/OL]. Science, 1956, 124(3212):103-104. eprint: <https://www.science.org/doi/pdf/10.1126/science.124.3212.103>. <https://www.science.org/doi/abs/10.1126/science.124.3212.103>.
- [6] ZUBER K. Neutrino Physics[M/OL]. CRC Press, 2020. <https://books.google.ca/books?id=6-XkDwAAQBAJ>.
- [7] GOEPPERT-MAYER M. Double Beta-Disintegration[J/OL]. Phys. Rev., 1935, 48:512-516. <https://link.aps.org/doi/10.1103/PhysRev.48.512>.
- [8] NAVAS S, et al. Review of particle physics[J]. Phys. Rev. D, 2024, 110(3):030001.
- [9] FURRY W H. On Transition Probabilities in Double Beta-Disintegration[J/OL]. Phys. Rev., 1939, 56:1184-1193. <https://link.aps.org/doi/10.1103/PhysRev.56.1184>.
- [10] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural computation, 1997, 9(8):1735-1780.
- [11] CHO K, van MERRIENBOER B, GÜLÇEHRE Ç, et al. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation[J/OL]. CoRR, 2014, abs/1406.1078. arXiv: 1406.1078. <http://arxiv.org/abs/1406.1078>.
- [12] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [13] ABDAR M, POURPANAH F, HUSSAIN S, et al. A review of uncertainty quantification in deep learning: Techniques, applications and challenges[J/OL]. Information Fusion, 2021, 76:243-297. <https://www.sciencedirect.com/science/article/pii/S1566253521001081>.
- [14] LAKSHMINARAYANAN B, PRITZEL A, BLUNDELL C. Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles[C/OL]//GUYON I, LUXBURG U V, BENGIO S, et al. Advances in Neural Information Processing Systems: vol. 30. Curran Associates, Inc., 2017. https://proceedings.neurips.cc/paper_files/paper/2017/file/9ef2ed4b7fd2c810847ffa5fa85bce38-Paper.pdf.
- [15] ABDAR M, POURPANAH F, HUSSAIN S, et al. A Review of Uncertainty Quantification in Deep Learning: Techniques, Applications and Challenges[J/OL]. CoRR, 2020, abs/2011.06225. arXiv: 2011.06225. <https://arxiv.org/abs/2011.06225>.
- [16] KULLBACK S, LEIBLER R A. On Information and Sufficiency[J/OL]. The Annals of Mathematical Statistics, 1951, 22(1):79-86 [2025-04-13]. <http://www.jstor.org/stable/2236703>.

- [17] ADAMS D Q, ALDUINO C, ALFONSO K, et al. Measurement of the $2\nu\beta\beta$ Decay Half-Life of ^{130}Te with CUORE[J/OL]. Phys. Rev. Lett., 2021, 126: 171801. <https://link.aps.org/doi/10.1103/PhysRevLett.126.171801>.
- [18] SCIELZO N D, CALDWELL S, SAVARD G, et al. Double- β -decay Q values of ^{130}Te , ^{128}Te , and ^{120}Te [J/OL]. Phys. Rev. C, 2009, 80: 025501. <https://link.aps.org/doi/10.1103/PhysRevC.80.025501>.
- [19] Von KROSIGK B. Measurement of proton and alpha-particle quenching in LAB based scintillators and determination of spectral sensitivities to supernova neutrinos in the SNO+ detector [D]. Dresden: Technical University of Dresden, 2015.
- [20] ANDERSON M. Studies of machine learning to improve sensitivities for the SNO+ detector and a local p-type point contact high purity germanium detector[D]. Kingston: Queen's University, 2024.
- [21] POWELL M J. An efficient method for finding the minimum of a function of several variables without calculating derivatives[J]. The computer journal, 1964, 7(2): 155-162.
- [22] ALLEGA A, ANDERSON M R, ANDRINGA S, et al. Event-by-event direction reconstruction of solar neutrinos in a high light-yield liquid scintillator[J/OL]. Physical Review D, 2024, 109(7). <http://dx.doi.org/10.1103/PhysRevD.109.072002>.

致 谢

光阴似箭，四载大学时光转瞬即逝。回首望去，这段旅程充满了探索与成长。本论文的顺利完成，凝聚了众多师长、同学和亲友的关心与帮助，在此谨致以最诚挚的谢意。

首先，我要特别感谢我的导师，山东大学张洋教授。张老师不仅引领我进入了中微子探测这一引人入胜的研究领域，为我提供了宝贵的研究机会，更在整个研究过程中给予了我悉心的指导和宝贵的支持，使我得以不断探索和进步。

同时，衷心感谢欧阳帅师兄和王菲师姐。他们在我研究起步阶段，耐心解答了我许多基础问题，帮助我扫清了诸多障碍，为我在 SNO+ 实验的研究奠定了坚实基础。

在加拿大阿尔伯塔大学学习交流期间，Aksel Hallin 教授、杨绍凯老师、胡捷老师、David Auty 老师以及 Muhammad Mubasher 同学、Muhammad Sadegh Esmaeilian 同学在学业和生活上均给予了我无私的帮助和指导，在此一并表示感谢。

感谢 SNO+ 合作组全体成员，在论文分析和数据准备过程中提供的支持与协助。

感谢 2021 级泰山学堂物理取向的全体同学。与各位并肩学习、共同生活的点点滴滴，是我大学生涯中珍贵的记忆。我们相互扶持，共同进步，这段同窗情谊将永远铭记于心。

最后，我要向我的父母和家人表达最深切的感谢。你们无条件的支持、理解与关爱，是我能够专注于学业、克服困难的最坚强后盾。

由于学识所限，文中疏漏在所难免，恳请各位老师和专家不吝赐教，批评指正。

附录 A 池化

池化 (Pooling)，也称为子采样 (Subsampling) 或下采样 (Downsampling)，是深度学习中常用的一种操作，尤其是在 CNN (Convolutional Neural Network, 卷积神经网络) 和处理序列数据的模型中。其主要目的包括降低维度、增强特征不变性以及增大感受野。

首先，池化层在处理特征图或序列信息时，通过将输入中的数据整合起来，有效地减少了后续层所需处理的参数和计算量，这样可以帮助降低模型的复杂度，避免过拟合。同时，池化操作还能增强模型应对输入细微变化的能力，例如平移或旋转，从而实现特征的不变性。此外，在卷积神经网络中，池化还能扩大感受野，使模型可以观察到更大范围的上下文信息，从而提升对整体结构的理解。

A.1 模型中的池化应用：带掩码的平均池化

在这个特定的模型中，输入是可变长度的 PMT 命中序列。经过特征嵌入和 GPT 编码器处理后，我们得到一个形状为 $(T \times d_{in})$ 的输出序列 X_{enc} ，其中 T 是序列长度 (可能包含填充)， d_{in} 是模型的内部嵌入维度。由于输入序列的长度 T 是可变的，并且为了进行最终的顶点位置回归 (需要一个固定大小的输入)，我们需要将这个可变长度的序列 X_{enc} 聚合 (或“池化”) 成一个单一的、固定大小的向量。

该模型采用的是带掩码的平均池化 (Masked Average Pooling)。选择这种方法主要是因为它能够有效处理变长序列，将不同长度的序列映射到相同维度的输出。同时，由于目标是基于整个事件 (所有有效命中) 的信息来预测顶点，需要聚合全局信息，全局池化是实现这一目标的自然选择。此外，由于较短的序列会被填充 (padding) 到最大长度 ‘max_seq_len’，在聚合信息时必须忽略填充部分，掩码 (Mask) 机制正好用于识别并忽略这些填充位置。最后，选择平均池化是因为它考虑了所有有效命中的贡献，将它们的特征表示进行平均，得到一个能代表整个事件“平均”特征的向量。相比之下，最大池化可能只关注最“突出”的少数命中，而对于顶点重建任务，综合所有命中的信息通常更为合理。

A.1.1 具体实现

令 $X_{enc} = [x_1, x_2, \dots, x_T]^T \in \mathbb{R}^{T \times d_{in}}$ 为 GPT 编码器的输出序列，其中 $x_i \in \mathbb{R}^{d_{in}}$ 。令 $M = [m_1, m_2, \dots, m_T]$ 为对应的二进制掩码，其中 $m_i = 1$ 表示第 i 个位置是有效命中， $m_i = 0$ 表示该位置是填充。

带掩码的平均池化计算如下：

$$\bar{x}_{pool} = \frac{\sum_{i=1}^T x_i \cdot m_i}{\sum_{i=1}^T m_i + \epsilon}$$

这个公式计算了所有有效命中 ($m_i = 1$) 对应的输出向量 x_i 的和，然后除以有效命中的数量 ($\sum_{i=1}^T m_i$)，得到平均向量 $\bar{x}_{pool} \in \mathbb{R}^{d_{in}}$ 。 ϵ 是一个小的常数以防止除零。

这个池化后的向量 \bar{x}_{pool} 捕获了整个事件序列的全局信息，并具有固定的维度 d_{in} 。它随后被送入层归一化 (Layer Normalization) 和最终的线性输出层，以预测事件的 (x, y, z) 坐标。

附录 B 层归一化

LN (Layer Normalization, 层归一化) 是一种在深度学习中广泛使用的归一化技术，特别是在处理序列数据（如 RNN (Recurrent Neural Network, 循环神经网络) 和 Transformer）时表现出色。与 BN (Batch Normalization, 批量归一化) 不同，BN 是在批次维度上对特征进行归一化，而 LN 是在单个样本的特征维度上进行归一化。

B.0.1 层归一化原理

对于神经网络某一层的一个样本的输出（或隐藏状态）向量 $h \in \mathbb{R}^d$ （其中 d 是该层的神经元数量或特征维度），层归一化首先计算该向量内所有元素的均值 μ 和标准差 σ ：

$$\mu = \frac{1}{d} \sum_{i=1}^d h_i$$

$$\sigma = \sqrt{\frac{1}{d} \sum_{i=1}^d (h_i - \mu)^2 + \epsilon}$$

其中 h_i 是向量 h 的第 i 个元素， ϵ 是一个很小的常数以防止除零。

然后，使用计算出的均值和标准差对该样本的输出向量 h 进行归一化：

$$\hat{h}_i = \frac{h_i - \mu}{\sigma}$$

最后，为了保持模型的表达能力，LN 引入了两个可学习的参数：增益 (gain) $\gamma \in \mathbb{R}^d$ 和偏置 (bias) $\beta \in \mathbb{R}^d$ （维度与 h 相同）。最终的输出 $LN(h)$ 计算如下：

$$LN(h)_i = \gamma_i \hat{h}_i + \beta_i$$

γ 和 β 在训练过程中与其他模型参数一起学习，允许网络自适应地缩放和平移归一化后的特征。

B.0.2 层归一化的优势

层归一化具有几个显著优势。首先，它的计算完全在单个样本内部进行，不依赖于批次中的其他样本，因此独立于批次大小 (Batch Size Independent)。这意味着 LN 在批次大小很小（甚至为 1）或变化时也能稳定工作，这对于 RNN 或处理变长序列的模型尤其有利。其次，对于变长的序列数据，不同时间步的统计特性可能不同，BN 在这种情况下可能效果不佳，而 LN 对每个时间步独立进行归一化，因此更适用于序列数据，具有更好的鲁棒性。最后，与 BN 类似，LN 有助于平滑损失曲面，稳定训练动态，从而稳定梯度并加速模型收敛。

B.0.3 在模型中的应用

根据前文池化章节的描述，在模型中，层归一化的应用紧随在带掩码的平均池化 (Masked Average Pooling) 步骤之后。具体流程是：带掩码的平均池化层输出了一个固定维度的向量 $\bar{x}_{pool} \in \mathbb{R}^{d_{in}}$ ，这个向量聚合了来自 GPT 编码器输出的整个事件序列的全局信息。然后，这个池化后的向量 \bar{x}_{pool} 被直接送入一个层归一化层。LN 层会计算 \bar{x}_{pool} 向量内部 d_{in} 个特征元素的均值和标准差，并对其进行归一化和仿射变换（使用可学习的 γ 和 β 参数）。在将聚合后的特征向量 \bar{x}_{pool} 输入到最终的线性输出层之前应用 LN，主要目的是稳定这一层输入的分布，减少内部协变量偏移 (Internal Covariate Shift)，有助于后续线性层更好地学习从全局特征到最终 (x, y, z) 坐标的映射，可能加速训练收敛并提高模型的泛化能力。最后，经过层归一化处理后的向量，再被送入最终的线性层进行坐标预测。